DACOS

CUBE

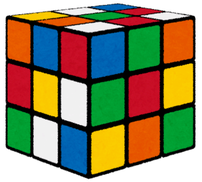

멀티에이전트 방식을 이용한 학습도우미

TEAM 에쁠쉐끼

위지우, 정세빈, 원지우, 김도연

PROJECT

목차

01 문제정의
02 페르소나
03 시행착오
04 엔진 설명
05 서비스 설명
06 확장 가능성 + 추후 보완사항
07 팀원 설명
08 Q&A

PROJECT

목차

01 문제정의
02 페르소나
03 시행착오
04 엔진 설명
05 서비스 설명
06 확장 가능성 + 추후 보완사항
07 팀원 설명
08 Q&A

문제 정의

ChatGPT

Ch6.pdf
PDF

이 PDF 전체를 학습 자료로 보고 중간고사 대비 문제 출제해줘.

중간고사 대비 연습문제 (PDF 전체 기반)

문제 1. (개념)

Association Analysis(연관 분석)의 기본 목적을 한 문장으로 설명하시오.

문제 2. (용어)

다음 중 **범주형(categorical) 속성**의 예로 알맞은 것은 무엇인가?

① Temperature = 23.8℃

② Age = 21

③ State = "California"

④ Income = 3,500,000

•

•

•

문제 14. (개념)

Sequential Pattern Discovery에서 후보 시퀀스의 수가 급격히 증가하는 이유 한 가지를 쓰시오.

문제 15. (개념)

Sequential Pattern Discovery에서도 Apriori 원리가 적용될 수 있는 이유를 간단히 설명하시오.

문제 정의

Ch6.pdf의 일부 페이지

Handling Categorical Attributes

- There are many data that contain ***categorical*** attributes
  - E.g., Internet survey data with categorical attributes

Gender	Level of Education	State	Computer at Home	Chat Online	Shop Online	Privacy Concerns
Female	Graduate	Illinois	Yes	Yes	Yes	Yes
Male	College	California	No	No	No	No
Male	Graduate	Michigan	Yes	Yes	Yes	Yes
Female	College	Virginia	No	No	Yes	Yes
Female	Graduate	California	Yes	No	No	Yes
...	...	...	...	...	...	...

- Using association analysis, we may uncover ***interesting rules***
  - E.g., {Shop Online = Yes} → {Privacy Concerns = Yes}

4

Transformation of Categorical Attributes

- To extract such patterns, we must ***transform*** the categorical attributes into "***items***" first
  - So that existing association rule mining algorithms can be applied
- We create a new ***item*** for each distinct ***attribute-value pair***

Male	Female	Education = Graduate	Education = College	...	Privacy = Yes	Privacy = No
0	1	1	0	...	1	0
1	0	0	1	...	0	1
1	0	1	0	...	1	0
0	1	0	1	...	1	0
0	1	1	0	...	1	0
...	...	...	...	...	...	...

an attribute-value pair

5

Preliminaries

- **Input**: a sequence data set
  - Each row records the occurrences of events with an object ***at a given time***
  - The ***timestamp*** information enables a different style of association analysis

Object	Timestamp	Events
A	10	2, 3, 5
A	20	1, 6
A	23	1
B	11	4, 5, 6
B	17	2
B	21	1, 2, 7, 8
C	14	1, 6
C	28	1, 7, 8

preprocessing →

A: <{2,3,5}{1,6}{1}>
B: <{4,5,6}{2}{1,2,7,8}>
C: <{1,6}{1,7,8}>

sequence data set

- **Output**: association patterns of events that commonly occur in a ***sequential order*** across objects
  - E.g., <{6}{1}> (i.e., event 6 is followed by event 1)
  - Such a pattern cannot be inferred using the traditional association analysis

27

Sequences (1/2)

- An ordered list of ***elements***
- A sequence can be denoted as $s = <e_1 e_2 e_3 \ldots e_n>$
  - $e_j = \{i_1, i_2, \ldots, i_k\}$: a collection of one or more ***events*** (items)
- Examples of sequences
  - Sequence of web pages viewed by a web site visitor
    - E.g., <{Homepage}{Electronics}{Cameras}{Shopping Cart}…>
  - Sequence of events leading to the nuclear accident
    - E.g., <{clogged resin}{outlet valve closure}{loss of feedwater}, …>
  - Sequence of classes taken by a software major student in each semester
    - E.g., <{Algorithm, OS}{DB, CA}{Network, SE}{Graphics, Mining}, …>

28

Sequential Pattern Discovery

- Let D be a dataset that contains one or more ***data sequences***
  - Data sequence: an ordered list of elements associated with a ***single*** object
  - The data set shown below contains five data sequences

Object	Timestamp	Events
A	1	1, 2, 4
A	2	2, 3
A	3	5
B	1	1, 2
B	2	2, 3, 4
C	1	1, 2
C	2	2, 3, 4
C	3	2, 4, 5
D	1	2
D	2	3, 4
D	3	4, 5
E	1	1, 3
E	2	2, 4, 5

preprocessing →

A: <{1,2,4}{2,3}{5}>
B: <{1,2}{2,3,4}>
C: <{1,2}{2,3,4}{2,4,5}>
D: <{2}{3,4}{4,5}>
E: <{1,3}{2,4,5}>

5 data sequences

- The support of a sequence s
  - The fraction of all data sequences that ***contain*** s
  - E.g., the support of <{1}{2}> = 4/5 = 80%

31

Problem Definition

Given a sequence dataset D and a user-specified minimum support threshold *minsup*, find ***all*** sequences with support ≥ *minsup*

- Example ($minsup = 50\%$)

Sequence dataset D:

A: <{1,2,4}{2,3}{5}>
B: <{1,2}{2,3,4}>
C: <{1,2}{2,3,4}{2,4,5}>
D: <{2}{3,4}{4,5}>
E: <{1,3}{2,4,5}>

→

Examples of Sequential Patterns:

<{1,2}>	s=60%
<{2,3}>	s=60%
<{2,4}>	s=80%
<{3}{5}>	s=80%
<{1}{2}>	s=80%
<{2}{2}>	s=60%
<{1}{2,3}>	s=60%
<{2}{2,3}>	s=60%
<{1,2}{2,3}>	s=60%

32

문제 정의

📍 기존 LLM의 한계

- PDF 분량 증가 → 전체 인식 한계
- 문제 유형 → 단순 조회형에 국한
- 표 기반 비교·분석 문제 생성 불가
- 시험 대비용 반복 연습 어려움

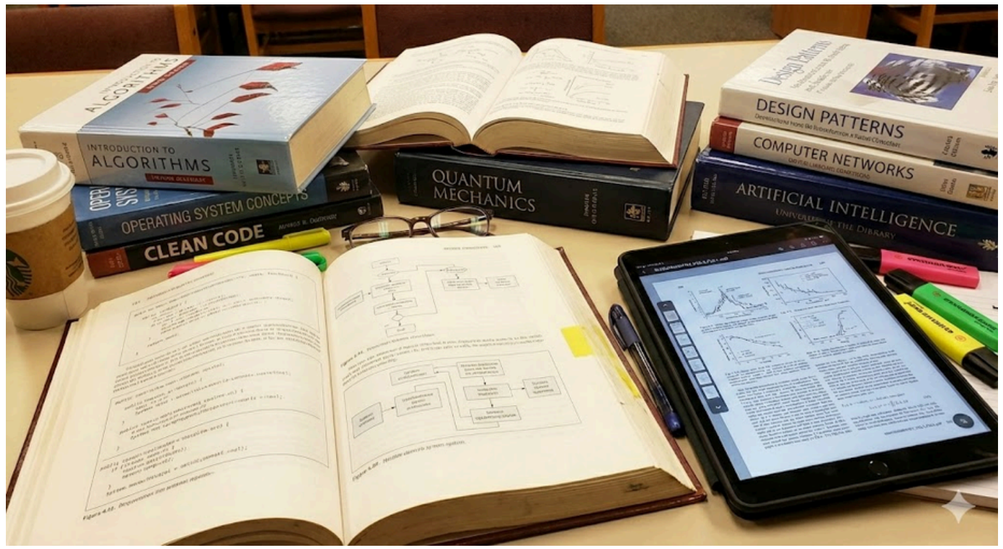

PROJECT

목차

01 문제정의
02 페르소나
03 시행착오
04 엔진 설명
05 서비스 설명
06 확장 가능성 + 추후 보완사항
07 팀원 설명
08 Q&A

페르소나

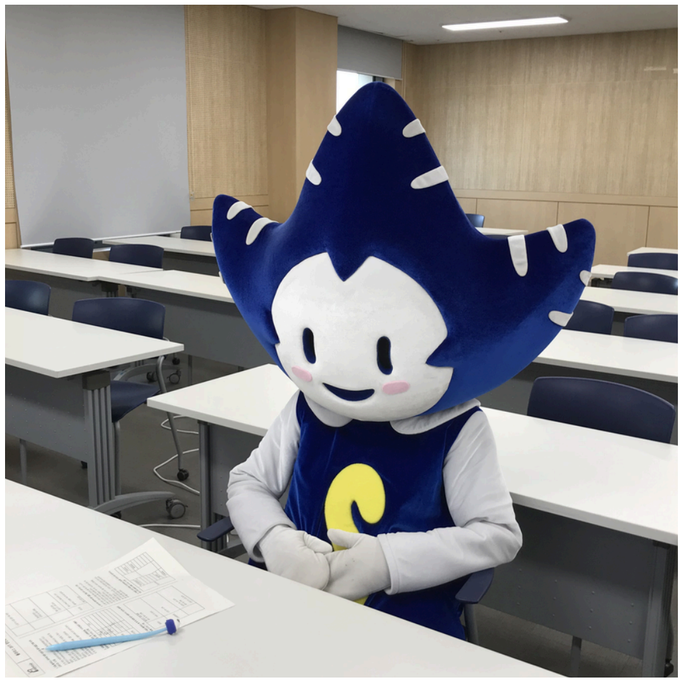

김눈송 (22세, 소프트웨어학부)

학습 배경

- 전공 강의 위주 학습
- 시험은 강의 슬라이드 기반
- 교재의 연습 문제/ 예제 수 부족

“강의자료로 문제를 충분히 풀고 싶은 학생”

BEFORE

문제 연습 과정

- 강의 PDF를 LLM에 그대로 업로드

→ 인식 누락 발생

- 표가 포함된 슬라이드

→ 문제 생성되지 않음

- 생성되는 문제

→ 단순 조회형 위주

결과

- 슬라이드 캡쳐 반복
- 문제 수·난이도 통제 불가
- 시험 대비 효율 낮음

CUBE 사용 후

- PDF 그대로 업로드
- 표 포함 슬라이드도 문제화-
- 비교·분석 중심 문제 자동 생성
- 채점 + 오답노트 제공

변화

- 반복 연습 가능
- 실전 대비 효율 향상
- 강의자료 하나로 시험 준비 가능

AFTER

문제 연습 과정

- 강의 PDF를 LLM에 그대로 업로드

→ 인식 누락 발생

- 표가 포함된 슬라이드

→ 문제 생성되지 않음

- 생성되는 문제

→ 단순 조회형 위주

결과

- 슬라이드 캡쳐 반복
- 문제 수·난이도 통제 불가
- 시험 대비 효율 낮음

CUBE 사용 후

- PDF 그대로 업로드
- 표 포함 슬라이드도 문제화-
- 비교·분석 중심 문제 자동 생성
- 채점 + 오답노트 제공

변화

- 반복 연습 가능
- 실전 대비 효율 향상
- 강의자료 하나로 시험 준비 가능

PROJECT

목차

01 문제정의
02 페르소나
03 시행착오
04 엔진 설명
05 서비스 설명
06 확장 가능성 + 추후 보완사항
07 팀원 설명
08 Q&A

우리가 풀려는 첫번째 문제

llm이 pdf내 표를 무시하지 않고 모두 이해한 뒤 문제 생성을 하려면 어떻게 해야할까?

⬇

먼저 표를 LLM이 인식 가능한 형태(JSON/CSV/Markdown)로 추출하자!

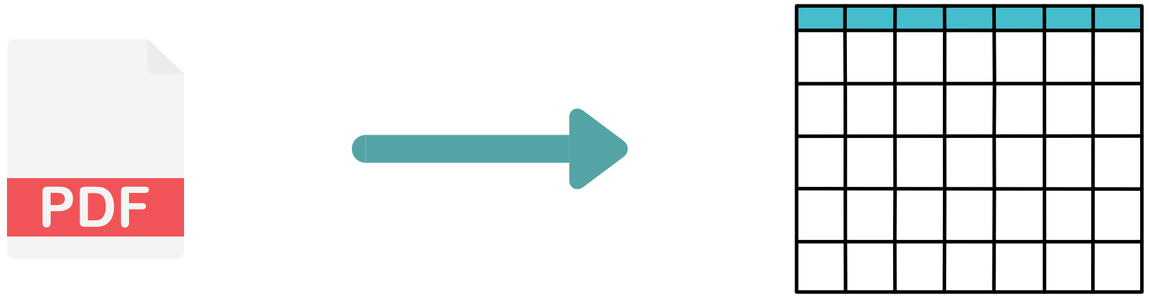

1. 문서 이해 모델을 이용해 PDF를 통째로 이해시켜보자

→ OCR-Free VQA / Document 이해 모델로 실험

모델	시도한 작업	결과	핵심 분석	최종 판단
Pix2Struct-VQA	페이지 전체 질의응답	실패	“정답 요약” 성향 강함 → 본문·표 전체 덤프 불가	❌ 부적합
Donut-Base (naver-clova-ix)	페이지 전체 텍스트/구조	대실패	문서 스타일 민감, 쓰레기 토큰 출력, 표 무시	❌ 부적합

=> 모델이 “추출”보다 “요약/답변”에 최적화됨
표를 구조로 뽑지 않고 중요하지 않은 요소처럼 생략하거나 축약

2. Table 전용 모델로 구조를 추출해보자

→ OCR-Free Table 전용 모델

모델	시도한 작업	결과	핵심 분석	최종 판단
Pix2Struct-Table	페이지 전체 테이블 추출	대실패	table 아닌 텍스트를 표로 오인	❌ 단독 불가
Table Transformer	표 탐지	실패	“이미 잘린 표” 전제 모델	❌ 단독 불가
LGPMA	표 구조 복원	부분 성공	탐지 단계 없음	⚠️ 후단 전용
TableFormer	셀/행/열 구조 예측	성공(조건부)	table bbox가 정확할 때만 SOTA	⚠️ 파이프라인용

=> 입력이 이미 잘린 ‘표 이미지’ 라는 가정
표 위치를 모르면 추출 단계로 못 들어감!

3. 레이아웃 모델로 table bbox 먼저 잡기

→ Layout / 레이아웃 감지 모델

모델	시도한 작업	결과	핵심 분석	최종 판단
LayoutParser (PubLayNet)	table 영역 bbox 감지	절반 성공	데이터셋 스타일 편향 심함	⚠️ 보조 수단
DocLayNet 계열	레이아웃 분류	개념적 성공	설치·사용 난이도 높음	⚠️ 연구용

=> 학습 데이터 스타일에 편향되어
강의 자료 속의 다양한 스타일의 경우 일반화 실패

4. 문서 구조화 파이프라인 (IBM Docling)모델 사용

→ 레이아웃 감지 후 구조 복원을 한 파이프라인으로!

구성 요소	역할	성능 평가	핵심 포인트
레이아웃 감지 모델	table / text / title bbox	우수	탐지가 성능의 70%
TableFormer	구조 복원	우수	bbox 정확도가 생명
Docling Pipeline	전체 자동화	안정적	단독 분해 사용 어려움

=> 파이프라인 무겁고 분해 사용 어려움, 일부 표 인식 불가 (완벽X)

실패 원인 분석

"왜 pdf 내 테이블 추출이 잘되지 않았을까?"

=> pdf 내 존재하는 테이블의 유형이 매우 다양했음!

"표 = 하나의 형태" (x)

유형	실제 페이지	특징	사람이 보기엔
일반 텍스트	2,4,5,8,9,10,12~15,18,19	순수 텍스트 레이어	그냥 본문
벡터 테이블	6, 7, 11	PDF 내부 선/텍스트로 구성	깔끔한 표
이미지 테이블	16, 17	스캔/이미지 기반	표
그림 취급 테이블	3	표처럼 생겼지만 figure 객체	표

pdf 내 테이블 유형이 다양한 문제

해결 전략 1

=> 다양한 표의 유형에 따라 각각 따로 추출 하는 전략?

- 1차 스캔: pdfplumber 기반 (벡터 레이어 신뢰 전략)
- 2차 스캔: LayoutParser + Tesseract (시각 기반 보완)

문제

1. 파이프라인 복잡도 폭증
2. 표 “구조”는 여전히 불안정
3. PDF 스타일에따른 유지보수성 문제

pdf 내 테이블 유형이 다양한 문제

규칙 기반 + OCR 접근의 한계

문서 스타일이 바뀔 때마다 예외 처리가 끝없이 늘어난다

=> 표를 ‘형태’가 아니라 ‘의미적 객체’로 인지하고,
사람처럼 표 자체를 인식하여 즉시 판단·추출할 수 있는 모델이 필요

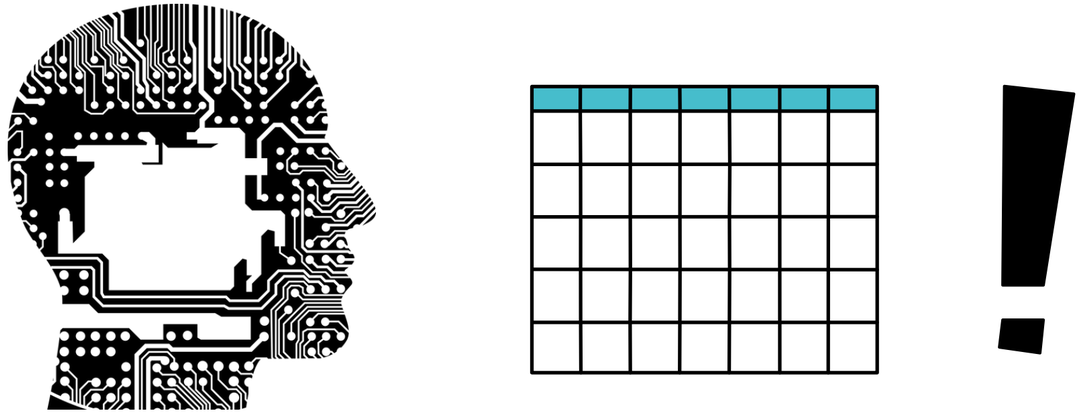

최종 채택 방식

→ VLM 기반 표 탐지 후 해당 페이지만 표 추출

1. 페이지별 표 존재 여부 판단	**GPT-4o (Vision)**
2. 표 있는 페이지만 필터링	rule-based
2. 해당 페이지 내 표 json 형태로 추출	**GPT-4o(Vision)**

우리가 풀려는 두번째 문제

llm이 50장이 넘는 pdf를 수용할 수 있게하려면 어떻게 해야할까?

⬇

LLM이 수용 가능 범위로 ppt를 적절하게 쪼개서 분배한뒤 입력으로 제공

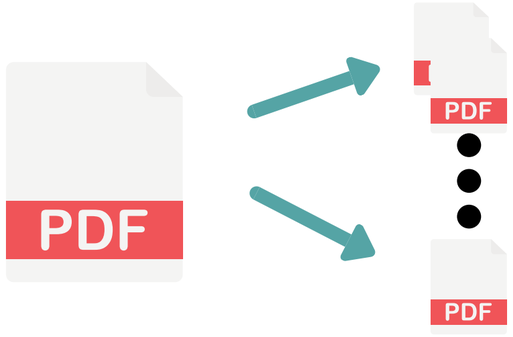

PROJECT

목차

01 문제정의
02 페르소나
03 시행착오
04 엔진 설명
05 서비스 설명
06 확장 가능성 + 추후 보완사항
07 팀원 설명
08 Q&A

메인 엔진 작동 과정

PDF +문제 수

↓

PARSING

↓

PLANNING

↓

GENERATION

↓

VERIFICATION

PARSING

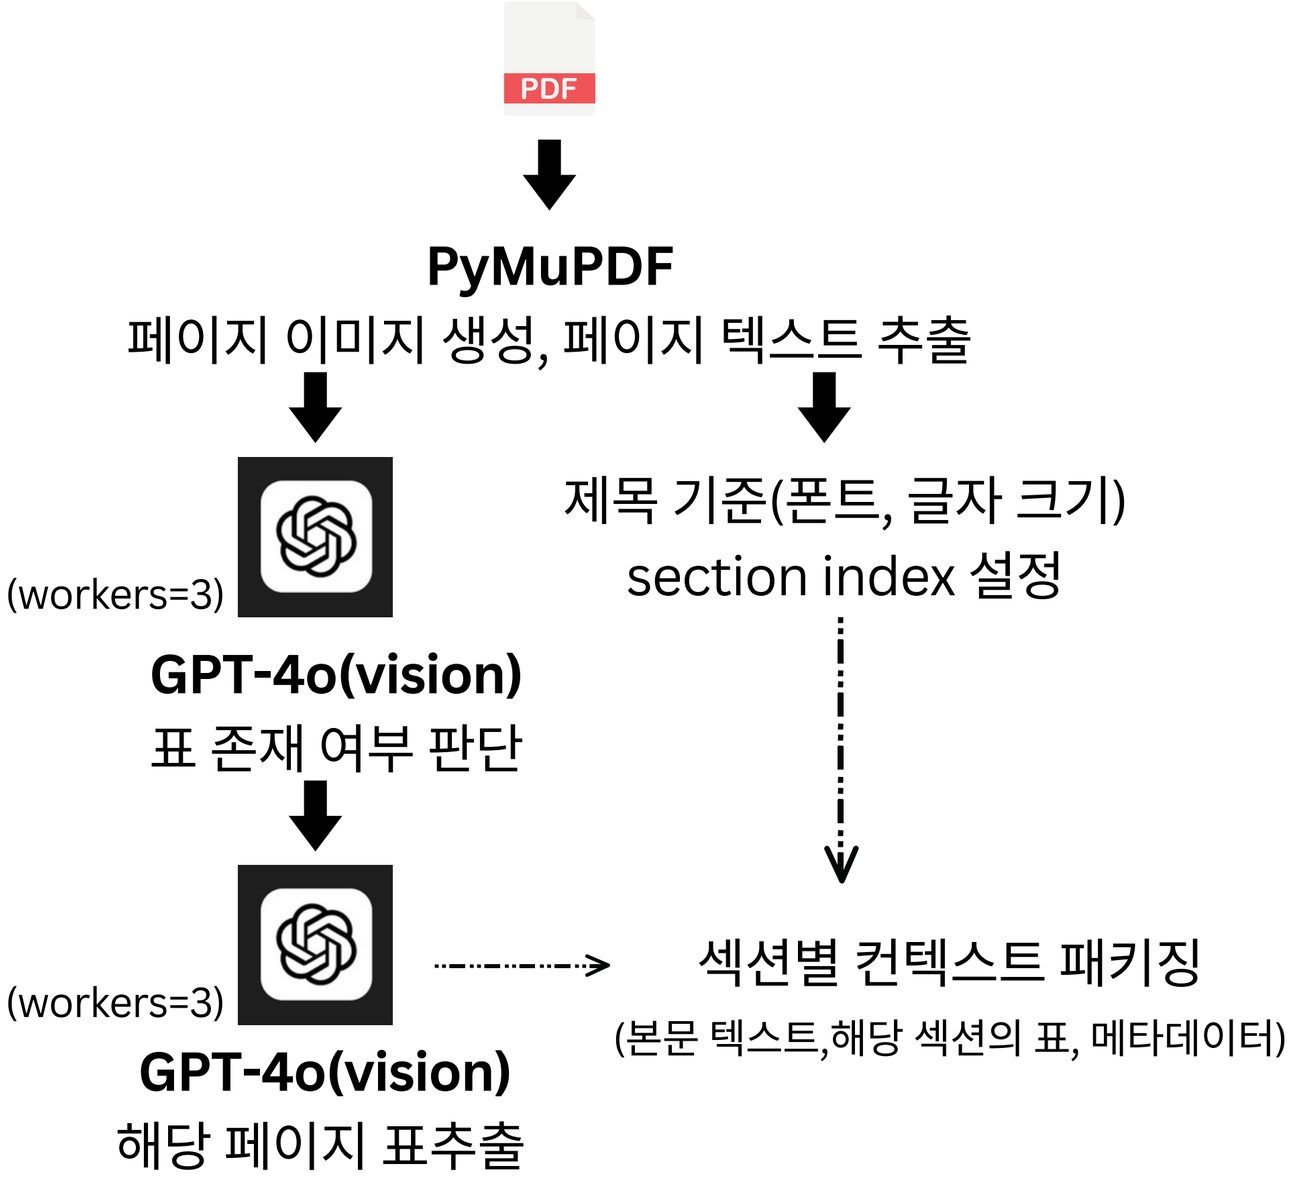
PDF
PyMuPDF
페이지 이미지 생성, 페이지 텍스트 추출
(workers=3)
GPT-4o(vision)
표 존재 여부 판단
(workers=3)
GPT-4o(vision)
해당 페이지 표추출
제목 기준(폰트, 글자 크기)
section index 설정
섹션별 컨텍스트 패키징
(본문 텍스트,해당 섹션의 표, 메타데이터)

PLANNING

섹션 컨텍스트, 문제 수

⬇

섹션 로컬 분석/요약

- TF-IDF로 키워드 추출
- 길이/표개수/코드/수식 여부 통계
- 템플릿 기반 summary 문자열 생성

⬇

GPT-4o-mini

각 섹션별 문제 개수 배분

분배 기준

1. 교육적 중요도 (핵심 개념, 이론)
2. 내용 깊이 (텍스트 길이)
3. 실습 가능성 (코드, 표)

⬇

로컬 검증/보정

- 합계가 정확히 total_questions 되도록 조정
- 최대치(max_per_section) 제한
- 0개인 섹션은 최종에서 제거

⬇

Job 생성

GENERATION/VERIFICATION

Job 단위 입력에서 근거 분해

- 텍스트 → Evidence Chunk 분할
  → 출제 근거의 source가 됨

(workers=4)

GPT-4o-mini

job 단위 문제/근거/정답/
해설 생성

로컬 검증/보정

- 필수 필드 존재 확인
- Job 내 중복 문제 검사

재생성

GPT-4o-mini

LLM 기반 품질 검증

- 정답 정확성
- 해설–정답 일관성
- 문제 명확성
- MCQ 오답 선지 품질
- 복수 정답 가능성

Aggregate Verification

- 전체 OK 문제 수 확인
- 중복 제거
- 문제 부족 시 추가 재생성 (최대 2 라운드)

판정 결과

OK : 의미적으로 문제 없음
FIXABLE : 수정하면 사용 가능 → 수정
REJECT : 의미적으로 치명적 결함 → 버림

PROJECT

목차

01 문제정의
02 페르소나
03 시행착오
04 엔진 설명
05 서비스 설명
06 확장 가능성 + 추후 보완사항
07 팀원 설명
08 Q&A

서비스 개요

CUBE

“강의안 PDF만 올리면,
강의 내용에 맞는 문제·정답·해설·오답노트를 자동 생성하는 학습 보조 서비스”

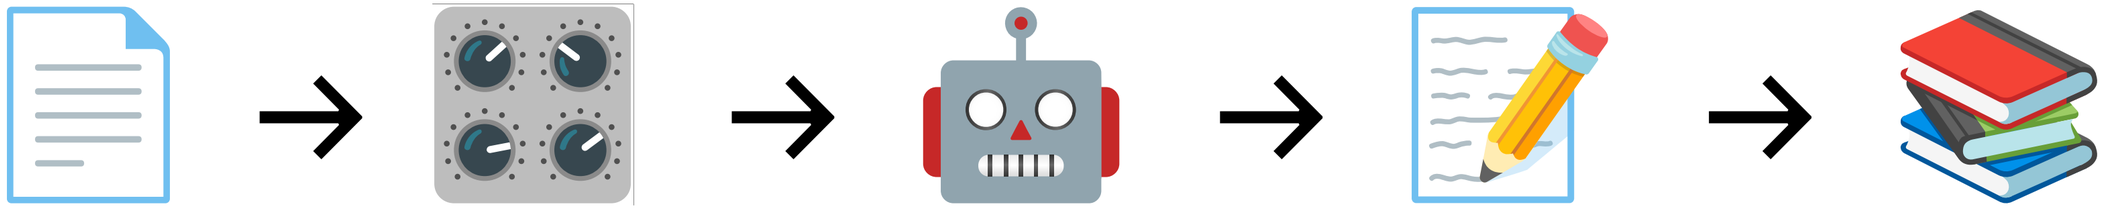

PDF 업로드 → 문제 생성 옵션 설정 → AI 문제 생성 → 문제 풀이 및 채점 → 오답노트 및 복습

PDF 인식

pdf 드랍 및 인식

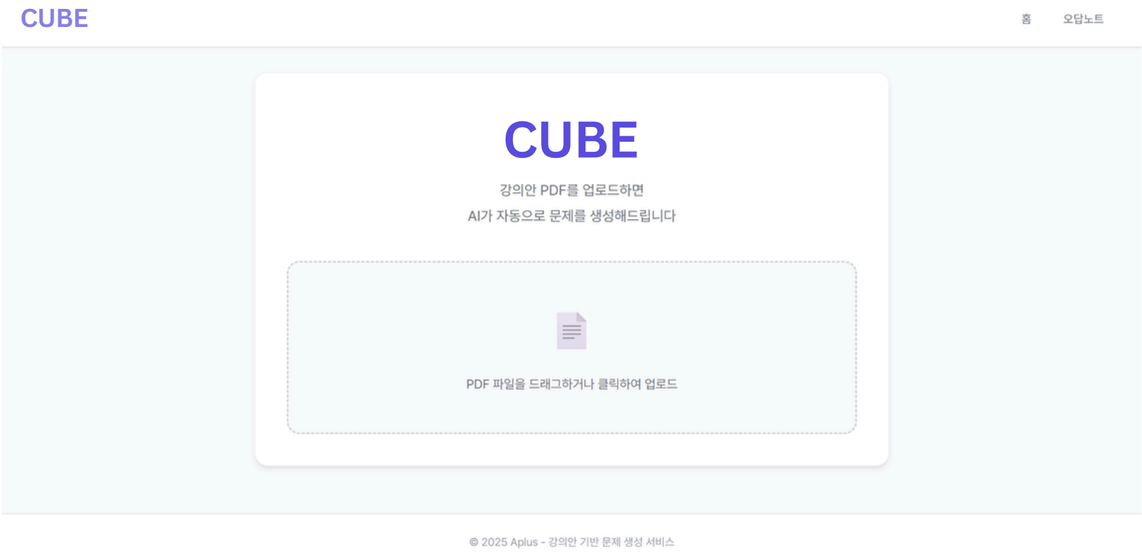

PDF 파일 업로드

드래그 앤 드롭 또는 파일 선택을 통해 강의안 PDF 업로드

자동 페이지 수 확인

업로드 된 PDF의 페이지 수를 자동으로 확인해 표시

문제 및 분할 설정

문제 개수,유형, 분할 장수 설정

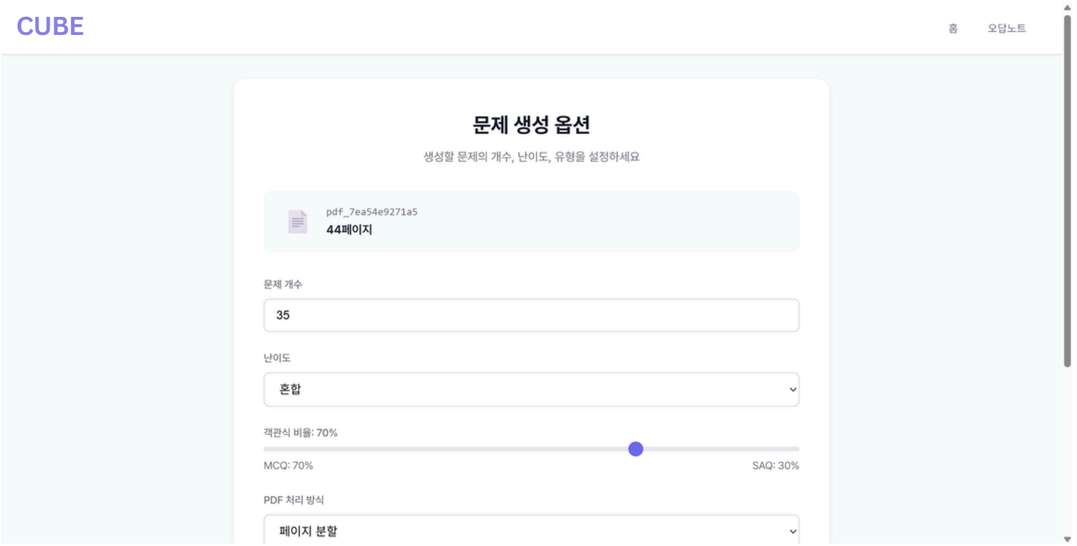

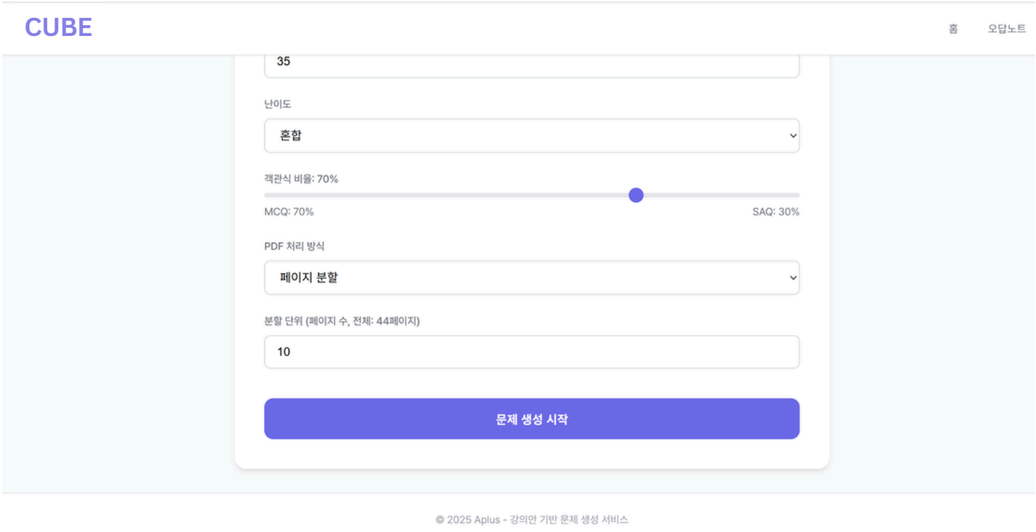

1.PDF 정보 표시

업로드한 PDF ID와 페이지 수 확인

2.문제 개수 설정

3.난이도 선택

쉬움, 보통, 어려움, 혼합 중 선택

3.문제 유형 비율 조정

객관식과 주관식의 비율을 슬라이더로 조정

4.PDF 처리 방식 선택

-전체 한번에: PDF 전체를 한 번에 분석

- 페이지 분할: 지정한 페이지 단위로 분할하여 분석

문제 생성 과정

표인식 및 문제 생성 진행 상황

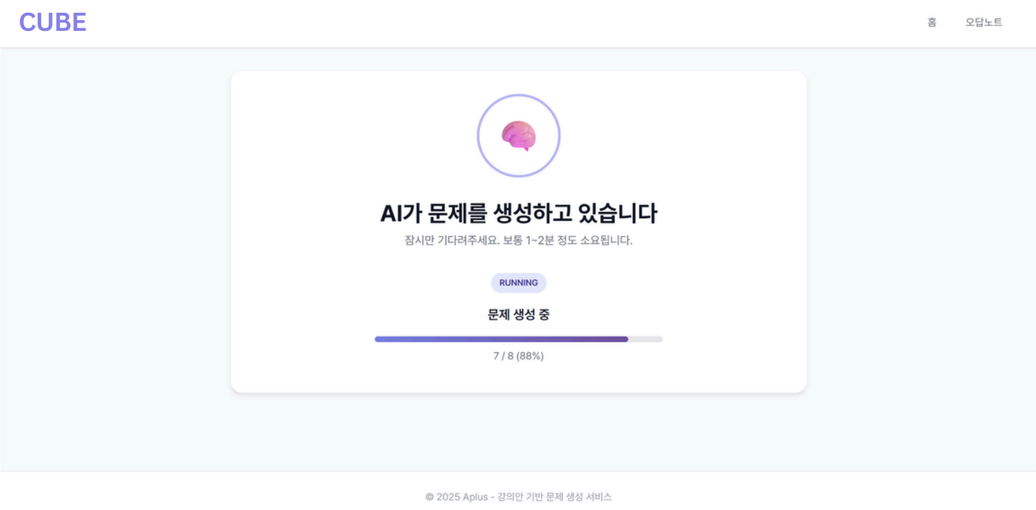

실시간 진행률

AI가 문제를 생성하는 단계별 과정

- PARSING: PDF 파싱 중
- GENERATING: 문제 생성 중
- VERIFYING: 문제 검증 중
- SAVING: 저장 중

진행률 바

각 단계별 완료된 작업 수와 전체 작업 수를 시각적으로 표시

예상 소요 시간 안내

일반적으로 1~2분 정도 소요된다는 안내 메시지

문제풀이

문제풀이 및 답안 제공

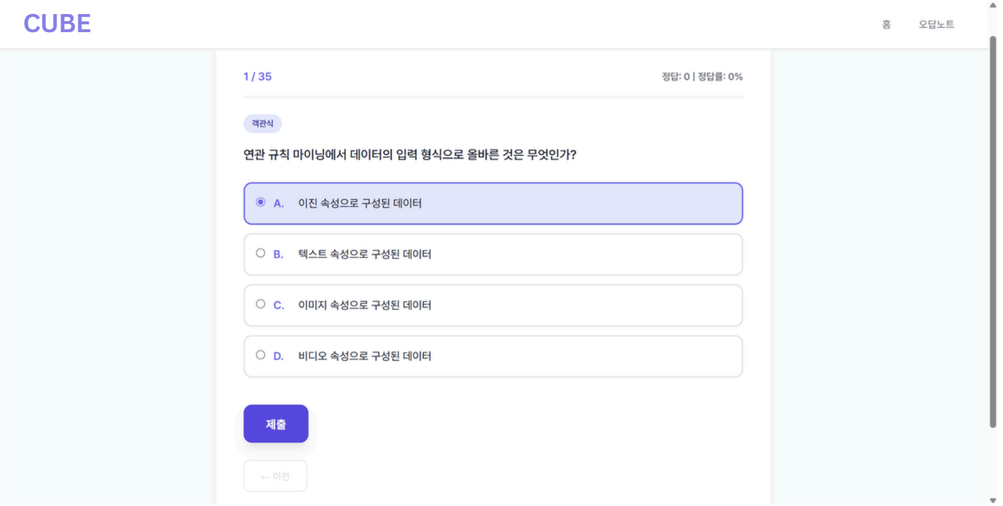

✅

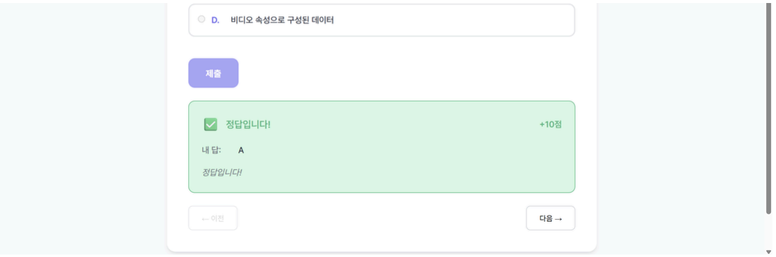

❌

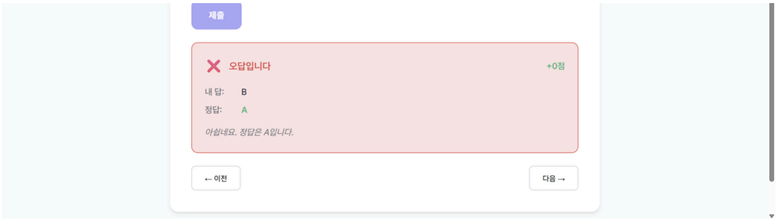

문제 카드 표시: 현재 문제를 카드 형태로 표시
- 객관식: 선택지 제공
- 주관식: 텍스트 입력 필드 제공

실시간 채점

답안 제출 시 즉시 채점 결과 제공
- 정답/오답 여부
- 점수
- 정답 내용

진행 상황 표시

현재 문제 번호와 전체 문제 수 표시

문제 네비게이션

이전/다음 문제로 이동 가능

완료 처리

모든 문제를 풀면 결과 확인 및 오답노트로 이동

오답노트

해설과 함께 제공되는 오답노트

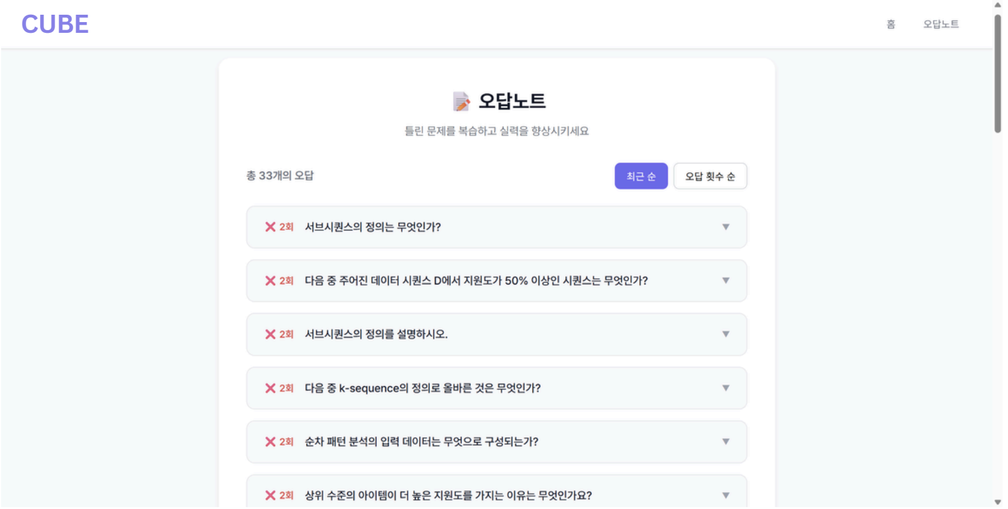

오답 문제 목록

틀린 문제들을 리스트 형태로 표시

통계 정보

전체 오답 문제 수 표시

복습 기능

오답노트에 저장된 문제를 다시 확인하고 학습 가능

문제 상세 정보

- 문제 내용
- 사용자가 입력한 답안
- 정답
- 상세 해설
- 틀린 횟수
- 마지막으로 틀린 시간

PROJECT

목차

01 문제정의
02 페르소나
03 시행착오
04 엔진 설명
05 서비스 설명
06 확장 가능성 + 추후 보완사항
07 팀원 설명
08 Q&A

향후 확장 방향

1 문제 유형 다양성

객관식, 단답형 중심의
제한된 문제 유형

↓

참/거짓, 빈칸, 서술형 등으로 유형 확장 예정
→ 프로그래밍 과목의 경우 **코드 완성형 문제까지 지**원

향후 확장 방향

2 데이터 관리 고도화 방향

파일시스템(JSON) 중심의
단순 저장 구조

↓

PostgreSQL/MongoDB 도입을 통해
PDF–표–문제–근거 간 관계형 데이터 관리 체계 구축 예정

향후 확장 방향

3 문제 생성 품질 향상

사용자 피드백 기반 지속적 품질 개선

과목별 특화 프롬프트 적용을 통한 정밀도 향상

향후 확장 방향

4 로그인 기능 구현

사용자 계정 관리 기능 부재

⬇️

로그인 기능 도입을 통해 사용자 식별 및 데이터 영속화

➕

개인별 문제 풀이 이력 기반

맞춤형 문제 제공 시스템으로 확장 예정

향후 확장 방향

5 노션 연동 기반 학습 플랫폼 확장

생성된 문제·해설을 **노션으로 자동 연동**
개인 학습 노트와 문제를 통합 관리
→ 학습 정리–문제 풀이–복습이 연결된 학습 환경 구축

CUBE

TEAM 에쁠쉐키

위지우

데이터사이언스전공 23

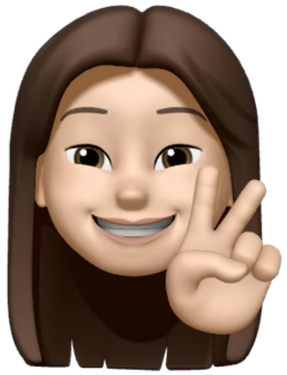

원지우

데이터사이언스전공 23

김도연

데이터사이언스전공 23

정세빈

데이터사이언스전공 24

Q&A

궁금한 점 질문해 주세요.

THANK YOU

TEAM 에쁠쉐끼🍎